

Universidad Autónoma de Entre Ríos

Facultad de Ciencia y Tecnología

Maestría en Ciencia de Datos

Trabajo Práctico Final

Precios históricos de combustibles en Paraná

Pamela Bonadeo

Orundés Cardinali Paolo

Mayo 2026

Contents

1	Introducción	2
2	Carga de paquetes y datos	2
3	Presentación de la base de datos	3
4	Descripción de variables	5
5	Análisis de datos faltantes	5
6	Análisis univariado	6
7	Intervalo de confianza para variable cualitativa	13
8	Intervalo de confianza para variable cuantitativa	14
9	Análisis de asociación	16
10	Comparación de grupos y pruebas de hipótesis	18
11	Modelos lineales	22
12	Identificación de outliers	24
13	Reducción de dimensión: PCA	26
14	Aporte personal	28
15	Conclusión general	31
16	Referencia del dataset	32

1 Introducción

El presente trabajo se realiza en el marco del Seminario 1: Técnicas de Análisis para la Ciencia de Datos, correspondiente a la Maestría en Ciencia de Datos de la FCyT - UADER.

El dataset seleccionado contiene precios históricos de combustibles correspondientes a la ciudad de Paraná. La base incluye información sobre empresas expendedoras, productos, precios, fechas de vigencia, banderas comerciales y coordenadas geográficas.

El objetivo general del trabajo es analizar la evolución histórica de los precios de combustibles en Paraná, identificar diferencias entre productos y banderas comerciales, detectar posibles valores atípicos y construir modelos estadísticos simples que permitan explicar el comportamiento del precio.

2 Carga de paquetes y datos

```
library(tidyverse)
```

```
## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
## v dplyr      1.2.1      v readr      2.2.0
## v forcats    1.0.1      v stringr   1.6.0
## v ggplot2    4.0.3      v tibble    3.3.1
## v lubridate  1.9.5      v tidyr     1.3.2
## v purrr      1.2.2
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()     masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```
library(lubridate)
library(janitor)
```

```
##
## Adjuntando el paquete: 'janitor'
##
## The following objects are masked from 'package:stats':
##
##      chisq.test, fisher.test
```

```
library(skimr)
library(vcd)
```

```
## Cargando paquete requerido: grid
```

```
library(factoextra)
```

```
## Welcome to factoextra!
## Want to learn more? See two factoextra-related books at https://www.datanovia.com/en/product/practice
```

```
combustibles <- read_delim(
  "data-set-precios-historicos-combustibles-parana.csv",
  delim = ";",
  locale = locale(encoding = "Latin1"),
  show_col_types = FALSE
)
```

```
combustibles <- combustibles %>%
  mutate(
    empresa = as.factor(empresa),
    producto = as.factor(producto),
    empresabandera = as.factor(empresabandera),
    fecha = dmy_hm(fecha_vigencia),
    anio = as.integer(anio),
    mes = as.integer(mes),
    mes_nombre = month(fecha, label = TRUE, abbr = FALSE),
    latitud_num = as.numeric(gsub("\\.", "", latitud)) / 100000,
    longitud_num = as.numeric(gsub("\\.", "", longitud)) / 100000
  )
```

3 Presentación de la base de datos

La base de datos utilizada contiene registros de precios de combustibles en Paraná. Cada fila representa un registro de precio asociado a una empresa, un producto, una fecha de vigencia y una bandera comercial.

```
head(combustibles)
```

```
## # A tibble: 6 x 13
##   empresa  producto precio fecha_vigencia empresabandera latitud longitud  anio
##   <fct>    <fct>    <dbl> <chr>          <fct>          <chr>   <chr>   <int>
## 1 BIOENERG~ Gas Oil~   17.0 30/3/2017 12:~ SOL PETROLEO   -3.173~ -6.052~ 2017
## 2 BIOENERG~ Gas Oil~   20.5 30/3/2017 12:~ SOL PETROLEO   -3.173~ -6.052~ 2017
## 3 BIOENERG~ Nafta (~ 22.5 30/3/2017 12:~ SOL PETROLEO   -3.173~ -6.052~ 2017
## 4 BIOENERG~ Nafta (~ 20.0 30/3/2017 12:~ SOL PETROLEO   -3.173~ -6.052~ 2017
## 5 BJA GNC ~ GNC      12.0 1/4/2017 07:35 BLANCA      -31.75~ -60.485~ 2017
## 6 BJA GNC ~ GNC      25.0 1/4/2019 14:00 BLANCA      -31.75~ -60.485~ 2019
## # i 5 more variables: mes <int>, fecha <dtm>, mes_nombre <ord>,
## #   latitud_num <dbl>, longitud_num <dbl>
```

```
str(combustibles)
```

```
## tibble [1,926 x 13] (S3: tbl_df/tbl/data.frame)
## $ empresa      : Factor w/ 9 levels "BIOENERGIA SRL",...: 1 1 1 1 2 2 2 2 2 2 ...
## $ producto     : Factor w/ 5 levels "Gas Oil Grado 2",...: 1 2 4 5 3 3 3 3 3 3 ...
## $ precio       : num [1:1926] 17 20.5 22.5 20 12 ...
## $ fecha_vigencia: chr [1:1926] "30/3/2017 12:27" "30/3/2017 12:28" "30/3/2017 12:27" "30/3/2017 12:28" ...
## $ empresabandera: Factor w/ 6 levels "BLANCA","GULF",...: 4 4 4 4 1 1 1 1 1 1 ...
## $ latitud      : chr [1:1926] "-3.173.979" "-3.173.979" "-3.173.979" "-3.173.979" ...
## $ longitud     : chr [1:1926] "-6.052.589" "-6.052.589" "-6.052.589" "-6.052.589" ...
## $ anio         : int [1:1926] 2017 2017 2017 2017 2017 2019 2025 2021 2022 2024 ...
```

```
## $ mes      : int [1:1926] 3 3 3 3 4 4 4 5 5 7 ...
## $ fecha    : POSIXct[1:1926], format: "2017-03-30 12:27:00" "2017-03-30 12:28:00" ...
## $ mes_nombre : Ord.factor w/ 12 levels "enero"<"febrero"<...: 3 3 3 3 4 4 4 4 5 5 7 ...
## $ latitud_num : num [1:1926] -31.7 -31.7 -31.7 -31.7 -317.6 ...
## $ longitud_num : num [1:1926] -60.5 -60.5 -60.5 -60.5 -604.9 ...
```

```
dim(combustibles)
```

```
## [1] 1926 13
```

```
summary(combustibles)
```

```
##          empresa          producto
## EDUARDO MATEOS SRL      :798 Gas Oil Grado 2      :464
## EL EMPALME S.R.L.       :372 Gas Oil Grado 3      :450
## COMBUSTIBLES PARANA SAS :305 GNC                  :103
## EBERLE, CLAUDIO FRANCISCO :242 Nafta (premium) de más de 95 Ron:454
## DAMARRA S.R.L.          :115 Nafta (súper) entre 92 y 95 Ron :455
## BJA GNC DE BARON JOSE ANTONIO: 80
## (Other)                  : 14
##      precio      fecha_vigencia      empresabandera
## Min.   : 9.69 Length:1926      BLANCA      :205
## 1st Qu.: 53.98 Class :character GULF        :305
## Median : 235.95 Mode  :character SHELL C.A.P.S.A.:798
## Mean   : 599.19      SOL PETROLEO : 4
## 3rd Qu.:1207.75      VOY          :242
## Max.   :7539.00      YPF          :372
##
##      latitud      longitud      anio      mes
## Length:1926      Length:1926      Min.   :2017      Min.   : 1.000
## Class :character Class :character 1st Qu.:2019      1st Qu.: 3.000
## Mode  :character Mode  :character Median :2023      Median : 6.000
##                                     Mean  :2022      Mean  : 6.286
##                                     3rd Qu.:2024      3rd Qu.:10.000
##                                     Max.   :2026      Max.   :12.000
##
##      fecha      mes_nombre      latitud_num
## Min.   :2017-01-12 19:24:00 marzo      :261      Min.   :-3.176e+09
## 1st Qu.:2019-11-14 00:00:00 diciembre:206      1st Qu.:-3.170e+02
## Median :2023-03-15 00:00:00 febrero   :185      Median :-3.170e+02
## Mean   :2022-06-03 16:10:06 enero      :181      Mean   :-3.991e+08
## 3rd Qu.:2024-08-24 19:45:00 noviembre:178      3rd Qu.:-3.200e+01
## Max.   :2026-05-15 14:00:00 abril      :154      Max.   :-3.200e+01
##                                     (Other) :761
##      longitud_num
## Min.   :-6.044e+09
## 1st Qu.:-6.050e+02
## Median :-6.050e+02
## Mean   :-7.595e+08
## 3rd Qu.:-6.100e+01
## Max.   :-6.000e+01
##
```

La dimensión del problema está dada por la cantidad de registros, la cantidad de variables disponibles y el período temporal cubierto por el dataset. En este caso, la base permite analizar la evolución de precios de distintos combustibles a lo largo de varios años.

4 Descripción de variables

Las principales variables del dataset son:

Variable	Descripción	Tipo
empresa	Empresa expendedora	Cualitativa nominal
producto	Tipo de combustible	Cualitativa nominal
precio	Precio registrado	Cuantitativa continua
fecha_vigencia	Fecha de vigencia del precio	Temporal
empresabandera	Bandera comercial	Cualitativa nominal
latitud	Latitud de la estación	Cuantitativa geográfica
longitud	Longitud de la estación	Cuantitativa geográfica
anio	Año del registro	Temporal / discreta
mes	Mes del registro	Temporal / discreta

5 Análisis de datos faltantes

Se analiza la presencia de valores faltantes por variable y en el total del dataset.

```
faltantes_por_variable <- combustibles %>%
  summarise(across(everything(), ~ sum(is.na(.)))) %>%
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "cantidad_faltantes"
  ) %>%
  mutate(
    porcentaje_faltantes = round(cantidad_faltantes / nrow(combustibles) * 100, 2)
  )
```

faltantes_por_variable

```
## # A tibble: 13 x 3
##   variable      cantidad_faltantes porcentaje_faltantes
##   <chr>          <int>          <dbl>
## 1 empresa            0            0
## 2 producto            0            0
## 3 precio              0            0
## 4 fecha_vigencia      0            0
## 5 empresabandera      0            0
## 6 latitud             0            0
## 7 longitud            0            0
## 8 anio                0            0
## 9 mes                 0            0
## 10 fecha              0            0
```

```
## 11 mes_nombre          0          0
## 12 latitud_num         0          0
## 13 longitud_num        0          0
```

```
sum(is.na(combustibles))
```

```
## [1] 0
```

En función del resultado obtenido, no se observan problemas relevantes de datos faltantes en las variables principales del dataset. Esto permite avanzar con el análisis descriptivo y estadístico sin necesidad de aplicar métodos de imputación.

6 Análisis univariado

El análisis univariado permite estudiar cada variable de manera individual. Para las variables cualitativas se construyen tablas de frecuencia y gráficos de barras. Para la variable cuantitativa principal, **precio**, se calculan medidas descriptivas y gráficos de distribución.

```
tabla_producto <- combustibles %>%
  count(producto, sort = TRUE) %>%
  mutate(porcentaje = round(n / sum(n) * 100, 2))
```

```
tabla_bandera <- combustibles %>%
  count(empresabandera, sort = TRUE) %>%
  mutate(porcentaje = round(n / sum(n) * 100, 2))
```

```
tabla_empresa <- combustibles %>%
  count(empresa, sort = TRUE) %>%
  mutate(porcentaje = round(n / sum(n) * 100, 2))
```

```
tabla_anio <- combustibles %>%
  count(anio) %>%
  mutate(porcentaje = round(n / sum(n) * 100, 2))
```

```
tabla_producto
```

```
## # A tibble: 5 x 3
##   producto          n porcentaje
##   <fct>          <int>     <dbl>
## 1 Gas Oil Grado 2    464      24.1
## 2 Nafta (súper) entre 92 y 95 Ron 455      23.6
## 3 Nafta (premium) de más de 95 Ron 454      23.6
## 4 Gas Oil Grado 3    450      23.4
## 5 GNC                103       5.35
```

```
tabla_bandera
```

```
## # A tibble: 6 x 3
##   empresabandera      n porcentaje
##   <fct>          <int>     <dbl>
```

```
## 1 SHELL C.A.P.S.A.    798    41.4
## 2 YPF                 372    19.3
## 3 GULF                305    15.8
## 4 VOY                 242    12.6
## 5 BLANCA              205    10.6
## 6 SOL PETROLEO        4      0.21
```

```
tabla_empresa
```

```
## # A tibble: 9 x 3
##   empresa                n porcentaje
##   <fct>                <int>     <dbl>
## 1 EDUARDO MATEOS SRL    798      41.4
## 2 EL EMPALME S.R.L.    372      19.3
## 3 COMBUSTIBLES PARANA SAS 305      15.8
## 4 EBERLE, CLAUDIO FRANCISCO 242      12.6
## 5 DAMARRA S.R.L.       115       5.97
## 6 BJA GNC DE BARON JOSE ANTONIO 80       4.15
## 7 CENTRO PARANA SRL      7       0.36
## 8 BIOENERGIA SRL        4       0.21
## 9 COOP. LA GANADERA GRAL. RAMIREZ LTDA. 3       0.16
```

```
tabla_anio
```

```
## # A tibble: 10 x 3
##   anio      n porcentaje
##   <int> <int>     <dbl>
## 1 2017   107      5.56
## 2 2018   231     12.0
## 3 2019   177      9.19
## 4 2020    83      4.31
## 5 2021   138      7.17
## 6 2022   166      8.62
## 7 2023   365     19.0
## 8 2024   261     13.6
## 9 2025   269     14.0
## 10 2026   129      6.7
```

```
resumen_precio <- combustibles %>%
  summarise(
    cantidad = n(),
    minimo = min(precio, na.rm = TRUE),
    q1 = quantile(precio, 0.25, na.rm = TRUE),
    media = mean(precio, na.rm = TRUE),
    mediana = median(precio, na.rm = TRUE),
    q3 = quantile(precio, 0.75, na.rm = TRUE),
    maximo = max(precio, na.rm = TRUE),
    desvio = sd(precio, na.rm = TRUE)
  )

resumen_precio
```




```
## # A tibble: 1 x 8
##   cantidad minimo    q1 media mediana    q3 maximo desvio
##   <int> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1    1926   9.69  54.0  599.   236. 1208.   7539   687.
```

```
resumen_precio_producto <- combustibles %>%
  group_by(producto) %>%
  summarise(
    cantidad = n(),
    media = round(mean(precio, na.rm = TRUE), 2),
    mediana = round(median(precio, na.rm = TRUE), 2),
    desvio = round(sd(precio, na.rm = TRUE), 2),
    minimo = min(precio, na.rm = TRUE),
    maximo = max(precio, na.rm = TRUE),
    .groups = "drop"
  )


resumen_precio_producto
```

```
## # A tibble: 5 x 7
##   producto                cantidad media mediana desvio minimo maximo
##   <fct>                  <int> <dbl>   <dbl> <dbl> <dbl> <dbl>
## 1 Gas Oil Grado 2          464  589.   231.   660.  16.8  2324
## 2 Gas Oil Grado 3          450  657.   297.   715.   9.69  2487
## 3 GNC                      103  242.    62.0  312.  11.0  1049
## 4 Nafta (premium) de más de 95 Ron    454  633.   246.   697.   9.74  2345
## 5 Nafta (súper) entre 92 y 95 Ron    455  599.   228.   714.  19.1  7539
```


```
ggplot(tabla_producto, aes(x = reorder(producto, n), y = n)) +
  geom_col() +
  coord_flip() +
  labs(title = "Cantidad de registros por producto", x = "Producto", y = "Cantidad")
```




```
ggplot(tabla_bandera, aes(x = reorder(empresabandera, n), y = n)) +
  geom_col() +
  coord_flip() +
  labs(title = "Cantidad de registros por bandera", x = "Bandera", y = "Cantidad")
```



```
ggplot(combustibles, aes(x = precio)) +  
  geom_histogram(bins = 30) +  
  labs(title = "Distribución de precios", x = "Precio", y = "Frecuencia")
```



```
ggplot(combustibles, aes(x = producto, y = precio)) +  
  geom_boxplot() +  
  coord_flip() +  
  labs(title = "Precio según producto", x = "Producto", y = "Precio")
```




```
precio_anio <- combustibles %>%
  group_by(anio) %>%
  summarise(
    precio_promedio = mean(precio, na.rm = TRUE),
    precio_mediano = median(precio, na.rm = TRUE),
    cantidad = n(),
    .groups = "drop"
  )
```

```
precio_anio
```

```
## # A tibble: 10 x 4
##   anio precio_promedio precio_mediano cantidad
##   <int>         <dbl>         <dbl>     <int>
## 1  2017          21.8          21.8       107
## 2  2018          33.2          32.0       231
## 3  2019          49.8          50.5       177
## 4  2020          66.4          67.7        83
## 5  2021         134.          83.9       138
## 6  2022         165.          163.       166
## 7  2023         352.          309.       365
## 8  2024        1149.         1169       261
## 9  2025        1472.         1494       269
## 10 2026        2011.         2019       129
```

```
ggplot(precio_anio, aes(x = anio, y = precio_promedio)) +
  geom_line() +
  geom_point() +
  labs(title = "Evolución del precio promedio por año", x = "Año", y = "Precio promedio")
```



El análisis univariado muestra la distribución de registros por producto, empresa, bandera comercial y año. Además, permite observar que la variable precio presenta dispersión, lo cual es esperable porque el dataset contiene diferentes tipos de combustibles y un período temporal amplio.

7 Intervalo de confianza para variable cualitativa

Para el análisis de una variable cualitativa se selecciona la variable **empresabandera** y se toma como categoría de interés **SHELL C.A.P.S.A.**. El objetivo es estimar la proporción de registros del dataset que corresponden a esa bandera comercial.

```
n_total <- nrow(combustibles)

n_shell <- combustibles %>%
  filter(empresabandera == "SHELL C.A.P.S.A.") %>%
  nrow()

ic_shell <- prop.test(
  x = n_shell,
  n = n_total,
```

```

    conf.level = 0.95,
    correct = FALSE
)

ic_shell

```

```

##
## 1-sample proportions test without continuity correction
##
## data:  n_shell out of n_total, null probability 0.5
## X-squared = 56.542, df = 1, p-value = 5.501e-14
## alternative hypothesis: true p is not equal to 0.5
## 95 percent confidence interval:
##  0.3925221 0.4364794
## sample estimates:
##          p
## 0.4143302

```

```

tabla_ic_shell <- tibble(
  variable = "empresabandera",
  categoria = "SHELL C.A.P.S.A.",
  total = n_total,
  cantidad_categoria = n_shell,
  porcentaje = round(n_shell / n_total * 100, 2),
  limite_inferior = round(ic_shell$conf.int[1] * 100, 2),
  limite_superior = round(ic_shell$conf.int[2] * 100, 2)
)

tabla_ic_shell

```

```

## # A tibble: 1 x 7
##   variable      categoria    total cantidad_categoria porcentaje limite_inferior
##   <chr>         <chr>      <int>          <int>      <dbl>         <dbl>
## 1 empresabandera SHELL C.A.~  1926             798      41.4          39.2
## # i 1 more variable: limite_superior <dbl>

```

El intervalo de confianza permite estimar, con un 95% de confianza, entre qué valores se encuentra la proporción de registros correspondientes a SHELL C.A.P.S.A. Esta interpretación debe limitarse al dataset analizado, ya que la base contiene registros de precios y no información sobre ventas o participación real de mercado.

8 Intervalo de confianza para variable cuantitativa

Para la variable cuantitativa se selecciona `precio`, ya que es la variable numérica central del trabajo. Se construye un intervalo de confianza del 95% para la media general del precio.

```

ic_precio <- t.test(combustibles$precio, conf.level = 0.95)

ic_precio

```

```
##
## One Sample t-test
##
## data: combustibles$precio
## t = 38.293, df = 1925, p-value < 2.2e-16
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
## 568.4978 629.8730
## sample estimates:
## mean of x
## 599.1854
```

```
tabla_ic_precio <- tibble(
  variable = "precio",
  media = round(mean(combustibles$precio, na.rm = TRUE), 2),
  desvio = round(sd(combustibles$precio, na.rm = TRUE), 2),
  limite_inferior = round(ic_precio$conf.int[1], 2),
  limite_superior = round(ic_precio$conf.int[2], 2)
)
```

```
tabla_ic_precio
```

```
## # A tibble: 1 x 5
##   variable media desvio limite_inferior limite_superior
##   <chr>      <dbl> <dbl>          <dbl>          <dbl>
## 1 precio    599.    687.          568.          630.
```

También se calculan intervalos de confianza para la media del precio según producto.

```
ic_precio_producto <- combustibles %>%
  group_by(producto) %>%
  summarise(
    n = n(),
    media = mean(precio, na.rm = TRUE),
    desvio = sd(precio, na.rm = TRUE),
    error = desvio / sqrt(n),
    li = media - qt(0.975, n - 1) * error,
    ls = media + qt(0.975, n - 1) * error,
    .groups = "drop"
  ) %>%
  mutate(across(where(is.numeric), ~ round(.x, 2)))
```

```
ic_precio_producto
```

```
## # A tibble: 5 x 7
##   producto          n media desvio error    li    ls
##   <fct>          <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 Gas Oil Grado 2    464  589.   660.   30.6  529.  650.
## 2 Gas Oil Grado 3    450  657.   715.   33.7  591.  723.
## 3 GNC                103  242.   312.   30.8  181.  303.
## 4 Nafta (premium) de más de 95 Ron 454  633.   697.   32.7  569.  698.
## 5 Nafta (súper) entre 92 y 95 Ron 455  599.   714.   33.5  533.  665.
```


El intervalo de confianza para la media del precio permite complementar el valor promedio observado con una medida de incertidumbre. Dado que los precios corresponden a distintos productos y años, resulta útil presentar también intervalos por producto.

9 Análisis de asociación

Se analiza la asociación entre las variables `producto` y `empresabandera`, ambas cualitativas. Para ello se utiliza una tabla de contingencia y una prueba de Chi-cuadrado.

```
tabla_producto_bandera <- table(combustibles$producto, combustibles$empresabandera)
```

```
tabla_producto_bandera
```

```
##
##
##          BLANCA GULF SHELL C.A.P.S.A. SOL PETROLEO
## Gas Oil Grado 2          27  78          201          1
## Gas Oil Grado 3          25  76          198          1
## GNC                    103   0           0           0
## Nafta (premium) de más de 95 Ron    25  76          202          1
## Nafta (súper) entre 92 y 95 Ron    25  75          197          1
##
##          VOY YPF
## Gas Oil Grado 2          64  93
## Gas Oil Grado 3          55  95
## GNC                      0   0
## Nafta (premium) de más de 95 Ron    56  94
## Nafta (súper) entre 92 y 95 Ron    67  90
```

```
chisq.test(tabla_producto_bandera, simulate.p.value = TRUE)
```

```
##
## Pearson's Chi-squared test with simulated p-value (based on 2000
## replicates)
##
## data:  tabla_producto_bandera
## X-squared = 915.56, df = NA, p-value = 0.0004998
```

```
assocstats(tabla_producto_bandera)
```

```
##          X^2 df P(> X^2)
## Likelihood Ratio 521.39 20      0
## Pearson          915.56 20      0
##
## Phi-Coefficient   : NA
## Contingency Coeff.: 0.568
## Cramer's V        : 0.345
```

La hipótesis nula plantea que no existe asociación entre el tipo de producto y la bandera comercial. Si el valor p es menor a 0,05, se rechaza la hipótesis nula y se concluye que existe asociación estadísticamente significativa entre ambas variables.

También se analiza la relación entre el año y el precio mediante correlaciones de Pearson y Spearman.

```
cor.test(combustibles$anio, combustibles$precio, method = "pearson")
```

```
##  
## Pearson's product-moment correlation  
##  
## data: combustibles$anio and combustibles$precio  
## t = 59.711, df = 1924, p-value < 2.2e-16  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
## 0.7896810 0.8210312  
## sample estimates:  
## cor  
## 0.8059204
```

```
cor.test(combustibles$anio, combustibles$precio, method = "spearman")
```


```
## Warning in cor.test.default(combustibles$anio, combustibles$precio, method =  
## "spearman"): Cannot compute exact p-value with ties
```

```
##  
## Spearman's rank correlation rho  
##  
## data: combustibles$anio and combustibles$precio  
## S = 26505414, p-value < 2.2e-16  
## alternative hypothesis: true rho is not equal to 0  
## sample estimates:  
## rho  
## 0.9777404
```

```
ggplot(combustibles, aes(x = anio, y = precio)) +  
  geom_point(alpha = 0.4) +  
  geom_smooth(method = "lm") +  
  labs(title = "Relación entre año y precio", x = "Año", y = "Precio")
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```

Relación entre año y precio



La relación entre año y precio permite analizar si los precios tienden a aumentar a medida que avanza el tiempo. Dado que se trabaja con precios nominales, se espera una relación positiva.

10 Comparación de grupos y pruebas de hipótesis

Para la comparación de grupos se seleccionaron dos productos comparables dentro del dataset: **Nafta (súper) entre 92 y 95 Ron** y **Nafta (premium) de más de 95 Ron**. La variable cuantitativa analizada fue el **precio**, mientras que la variable de agrupamiento fue el **producto**.

Como se comparan dos grupos independientes y no se asume igualdad de varianzas, se utiliza la **prueba t de Welch**. Esta prueba fue vista en clase y resulta adecuada cuando se desea comparar las medias de una variable cuantitativa entre dos grupos independientes con varianzas distintas o dudosas.

Se plantean las siguientes hipótesis:

- **Hipótesis nula:** el precio promedio de la Nafta (súper) es igual al precio promedio de la Nafta (premium).
- **Hipótesis alternativa:** el precio promedio de la Nafta (súper) es diferente al precio promedio de la Nafta (premium).

```
datos_naftas <- combustibles %>%  
  filter(producto %in% c(  
    "Nafta (súper) entre 92 y 95 Ron",  
    "Nafta (premium) de más de 95 Ron"  
  )) %>%
```

```

droplevels()

# Se verifica que quedaron exactamente dos grupos
levels(datos_naftas$producto)

## [1] "Nafta (premium) de más de 95 Ron" "Nafta (súper) entre 92 y 95 Ron"

resumen_naftas <- datos_naftas %>%
  group_by(producto) %>%
  summarise(
    cantidad = n(),
    media = round(mean(precio, na.rm = TRUE), 2),
    mediana = round(median(precio, na.rm = TRUE), 2),
    desvio = round(sd(precio, na.rm = TRUE), 2),
    minimo = min(precio, na.rm = TRUE),
    maximo = max(precio, na.rm = TRUE),
    .groups = "drop"
  )


resumen_naftas

## # A tibble: 2 x 7
##   producto                cantidad media mediana desvio minimo maximo
##   <fct>                  <int> <dbl>   <dbl>  <dbl>  <dbl>  <dbl>
## 1 Nafta (premium) de más de 95 Ron      454  633.    246.   697.    9.74  2345
## 2 Nafta (súper) entre 92 y 95 Ron      455  599.    228.   714.   19.1  7539

ggplot(datos_naftas, aes(x = producto, y = precio)) +
  geom_boxplot() +
  coord_flip() +
  labs(
    title = "Comparación de precios entre Nafta (súper) y Nafta (premium)",
    x = "Producto",
    y = "Precio"
  )

```

Comparación de precios entre Nafta (súper) y Nafta (premium)



Antes de aplicar la prueba se realiza una revisión de normalidad mediante Shapiro-Wilk y QQ plot. También se compara la dispersión entre ambos grupos mediante una prueba F de igualdad de varianzas.

```
by(datos_naftas$precio, datos_naftas$producto, shapiro.test)
```

```
## datos_naftas$producto: Nafta (premium) de más de 95 Ron
```

```
##
```

```
## Shapiro-Wilk normality test
```

```
##
```

```
## data: dd[x, ]
```

```
## W = 0.79608, p-value < 2.2e-16
```

```
##
```

```
## -----
```

```
## datos_naftas$producto: Nafta (súper) entre 92 y 95 Ron
```

```
##
```

```
## Shapiro-Wilk normality test
```

```
##
```

```
## data: dd[x, ]
```

```
## W = 0.73642, p-value < 2.2e-16
```

```
# Prueba F para comparar varianzas entre los dos grupos
```


```
var.test(precio ~ producto, data = datos_naftas)
```

```
##
```

```
## F test to compare two variances
```

```
##
## data:  precio by producto
## F = 0.9528, num df = 453, denom df = 454, p-value = 0.607
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.7924385 1.1456458
## sample estimates:
## ratio of variances
##      0.9528046
```

```
ggplot(datos_naftas, aes(sample = precio)) +
  stat_qq() +
  stat_qq_line() +
  facet_wrap(~ producto) +
  labs(title = "QQ plot del precio por tipo de nafta")
```



Luego se aplica la prueba t de Welch.

```
prueba_welch_naftas <- t.test(
  precio ~ producto,
  data = datos_naftas,
  var.equal = FALSE,
  conf.level = 0.95
)

prueba_welch_naftas
```

```
##
## Welch Two Sample t-test
##
## data: precio by producto
## t = 0.73485, df = 906.56, p-value = 0.4626
## alternative hypothesis: true difference in means between group Nafta (premium) de más de 95 Ron and
## 95 percent confidence interval:
## -57.45395 126.23081
## sample estimates:
## mean in group Nafta (premium) de más de 95 Ron
## 633.2243
## mean in group Nafta (súper) entre 92 y 95 Ron
## 598.8358
```

Si el valor p obtenido es menor a 0,05, se rechaza la hipótesis nula y se concluye que existen diferencias estadísticamente significativas entre los precios promedio de ambos tipos de nafta. Si el valor p es mayor o igual a 0,05, no se rechaza la hipótesis nula y no se cuenta con evidencia suficiente para afirmar que los promedios sean diferentes.

11 Modelos lineales

Se construyen modelos lineales tomando como variable dependiente el `precio`. Como variables explicativas se utilizan `anio` y `producto`.

```
modelo_1 <- lm(precio ~ anio, data = combustibles)
modelo_2 <- lm(precio ~ anio + producto, data = combustibles)

summary(modelo_1)
```

```
##
## Call:
## lm(formula = precio ~ anio, data = combustibles)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -706.0 -361.4   51.2  248.4  7133.8
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -4.096e+05  6.870e+03  -59.62  <2e-16 ***
## anio         2.029e+02  3.398e+00   59.71  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 406.7 on 1924 degrees of freedom
## Multiple R-squared:  0.6495, Adjusted R-squared:  0.6493
## F-statistic: 3565 on 1 and 1924 DF, p-value: < 2.2e-16
```

```
summary(modelo_2)
```

```
##
```

```
## Call:
## lm(formula = precio ~ anio + producto, data = combustibles)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -623.4 -367.4   59.3  256.7 7160.8
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -4.079e+05  6.798e+03  -60.002  < 2e-16
## anio             2.020e+02  3.362e+00   60.089  < 2e-16
## productoGas Oil Grado 3    7.447e+01  2.658e+01    2.802  0.00513
## productoGNC    -2.200e+02  4.381e+01   -5.021  5.6e-07
## productoNafta (premium) de más de 95 Ron  5.017e+01  2.652e+01    1.892  0.05868
## productoNafta (súper) entre 92 y 95 Ron -1.355e+01  2.651e+01   -0.511  0.60932
##
## (Intercept)          ***
## anio                  ***
## productoGas Oil Grado 3      **
## productoGNC              ***
## productoNafta (premium) de más de 95 Ron .
## productoNafta (súper) entre 92 y 95 Ron
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 401.7 on 1920 degrees of freedom
## Multiple R-squared:  0.6587, Adjusted R-squared:  0.6578
## F-statistic: 741 on 5 and 1920 DF, p-value: < 2.2e-16
```

```
metricas <- tibble(
  modelo = c("precio ~ anio", "precio ~ anio + producto"),
  r2 = c(summary(modelo_1)$r.squared, summary(modelo_2)$r.squared),
  r2_ajustado = c(summary(modelo_1)$adj.r.squared, summary(modelo_2)$adj.r.squared),
  rmse = c(
    sqrt(mean(residuals(modelo_1)^2)),
    sqrt(mean(residuals(modelo_2)^2))
  )
) %>%
  mutate(across(where(is.numeric), ~ round(.x, 4)))
```


```
metricas
```

```
## # A tibble: 2 x 4
##   modelo          r2 r2_ajustado  rmse
##   <chr>          <dbl>     <dbl> <dbl>
## 1 precio ~ anio    0.650     0.649  406.
## 2 precio ~ anio + producto 0.659     0.658  401.
```

```
combustibles_modelo <- combustibles %>%
  mutate(
    precio_estimado = predict(modelo_2),
    residuo = precio - precio_estimado
  )
```



```
ggplot(combustibles_modelo, aes(x = precio_estimado, y = precio)) +
  geom_point(alpha = 0.4) +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed") +
  labs(title = "Precio observado vs precio estimado", x = "Precio estimado", y = "Precio observado")
```



El modelo que incorpora `año` y `producto` permite explicar mejor el precio que el modelo que utiliza solamente el año. Sin embargo, se trata de un modelo exploratorio, ya que no incorpora otras variables relevantes como inflación, impuestos, tipo de cambio o costos logísticos.

12 Identificación de outliers

Para detectar valores atípicos se utiliza el método del rango intercuartílico. Se considera outlier a un valor ubicado por debajo de $Q1 - 1,5 * IQR$ o por encima de $Q3 + 1,5 * IQR$.

```
es_outlier <- function(x) {
  q1 <- quantile(x, 0.25, na.rm = TRUE)
  q3 <- quantile(x, 0.75, na.rm = TRUE)
  iqr <- IQR(x, na.rm = TRUE)
  x < q1 - 1.5 * iqr | x > q3 + 1.5 * iqr
}
```

```
combustibles_outliers <- combustibles %>%
  mutate(outlier_precio = es_outlier(precio))
```

```

outliers_precio <- combustibles_outliers %>%
  filter(outlier_precio) %>%
  select(empresa, producto, precio, fecha_vigencia, empresabandera, anio, mes)

outliers_precio

## # A tibble: 1 x 7
##   empresa      producto      precio fecha_vigencia empresabandera  anio  mes
##   <fct>      <fct>      <dbl> <chr>      <fct>      <int> <int>
## 1 DAMARRA S.R.L. Nafta (súper)~  7539 15/1/2021 21:~ BLANCA      2021    1

nrow(outliers_precio)

## [1] 1

combustibles_outliers <- combustibles %>%
  mutate(
    outlier_precio = es_outlier(precio),
    outlier_anio = es_outlier(anio),
    outlier_mes = es_outlier(mes),
    outlier_latitud = es_outlier(latitud_num),
    outlier_longitud = es_outlier(longitud_num),
    total_outliers = outlier_precio + outlier_anio + outlier_mes +
      outlier_latitud + outlier_longitud
  )

tabla_outliers <- tibble(
  variable = c("precio", "anio", "mes", "latitud", "longitud"),
  cantidad = c(
    sum(combustibles_outliers$outlier_precio),
    sum(combustibles_outliers$outlier_anio),
    sum(combustibles_outliers$outlier_mes),
    sum(combustibles_outliers$outlier_latitud),
    sum(combustibles_outliers$outlier_longitud)
  )
)

tabla_outliers

## # A tibble: 5 x 2
##   variable cantidad
##   <chr>      <int>
## 1 precio          1
## 2 anio            0
## 3 mes            0
## 4 latitud       242
## 5 longitud       242

filas_con_outliers <- combustibles_outliers %>%
  filter(total_outliers > 0) %>%
  select(

```

```

    empresa, producto, precio, fecha_vigencia, empresabandera,
    anio, mes, latitud_num, longitud_num, total_outliers
  )

filas_con_outliers

```

```

## # A tibble: 243 x 10
##   empresa producto precio fecha_vigencia empresabandera  anio  mes latitud_num
##   <fct>   <fct>   <dbl> <chr>           <fct>           <int> <int>   <dbl>
## 1 DAMARR~ Nafta (~   7539 15/1/2021 21:~ BLANCA           2021    1   -3.17e2
## 2 EBERLE~ Gas Oil~    925 1/2/2024 07:00 VOY           2024    2   -3.18e9
## 3 EBERLE~ Gas Oil~   1135 1/7/2024 07:00 VOY           2024    7   -3.18e9
## 4 EBERLE~ Gas Oil~   1351 1/7/2025 07:00 VOY           2025    7   -3.18e9
## 5 EBERLE~ Gas Oil~   1476 1/9/2025 07:00 VOY           2025    9   -3.18e9
## 6 EBERLE~ Gas Oil~   1174 1/10/2024 07:~ VOY           2024   10   -3.18e9
## 7 EBERLE~ Gas Oil~   1832 2/3/2026 07:00 VOY           2026    3   -3.18e9
## 8 EBERLE~ Gas Oil~   1082 2/5/2024 07:00 VOY           2024    5   -3.18e9
## 9 EBERLE~ Gas Oil~   1287 2/6/2025 07:00 VOY           2025    6   -3.18e9
## 10 EBERLE~ Gas Oil~    282 2/8/2023 09:30 VOY           2023    8   -3.18e9
## # i 233 more rows
## # i 2 more variables: longitud_num <dbl>, total_outliers <int>

```

```
nrow(filas_con_outliers)
```

```
## [1] 243
```

Este análisis permite identificar registros que podrían requerir revisión. Los outliers pueden representar errores de carga, situaciones excepcionales o valores reales poco frecuentes.

13 Reducción de dimensión: PCA

Para reducir la dimensión de un conjunto de variables cuantitativas se aplica un Análisis de Componentes Principales. Se utilizan las variables `precio`, `anio`, `mes`, `latitud_num` y `longitud_num`.

```

datos_pca <- combustibles %>%
  select(precio, anio, mes, latitud_num, longitud_num) %>%
  drop_na()

pca <- prcomp(datos_pca, center = TRUE, scale. = TRUE)

summary(pca)


```

```

## Importance of components:
##              PC1      PC2      PC3      PC4      PC5
## Standard deviation   1.6255 1.0991 0.9781 0.43950 1.15e-08
## Proportion of Variance 0.5285 0.2416 0.1913 0.03863 0.00e+00
## Cumulative Proportion 0.5285 0.7700 0.9614 1.00000 1.00e+00


```

```
fviz_eig(pca, addlabels = TRUE)
```



```
fviz_pca_biplot(  
  pca,  
  repel = TRUE,  
  title = "Biplot del PCA"  
)
```

Biplot del PCA



El PCA permite resumir la información de varias variables numéricas en una menor cantidad de componentes. El biplot permite observar la relación entre variables y registros, identificando posibles agrupamientos o direcciones de mayor variabilidad.

14 Aporte personal

Como aporte adicional se analiza la evolución mensual del precio promedio por producto y la variación porcentual interanual. Esto permite observar la dinámica temporal con mayor detalle.


```
precio_mensual <- combustibles %>%
  group_by(ano, mes, producto) %>%
  summarise(
    precio_promedio = mean(precio, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  mutate(fecha_mes = ymd(paste(ano, mes, "01", sep = "-")))
```

precio_mensual

```
## # A tibble: 430 x 5
##   ano  mes producto precio_promedio fecha_mes
##   <int> <int> <fct>      <dbl>   <date>
## 1  2017     1 Gas Oil Grado 2      18.5 2017-01-01
## 2  2017     1 Gas Oil Grado 3      21.7 2017-01-01
```

```
## 3 2017 1 Nafta (premium) de más de 95 Ron 24.2 2017-01-01
## 4 2017 1 Nafta (súper) entre 92 y 95 Ron 21.0 2017-01-01
## 5 2017 2 Gas Oil Grado 2 17.5 2017-02-01
## 6 2017 2 Gas Oil Grado 3 20.2 2017-02-01
## 7 2017 2 Nafta (premium) de más de 95 Ron 22.0 2017-02-01
## 8 2017 2 Nafta (súper) entre 92 y 95 Ron 19.8 2017-02-01
## 9 2017 3 Gas Oil Grado 2 17.7 2017-03-01
## 10 2017 3 Gas Oil Grado 3 20.9 2017-03-01
## # i 420 more rows
```

```
ggplot(precio_mensual, aes(x = fecha_mes, y = precio_promedio)) +
  geom_line() +
  facet_wrap(~ producto, scales = "free_y") +
  labs(title = "Evolución mensual del precio promedio", x = "Fecha", y = "Precio promedio")
```



```
precio_anual_producto <- combustibles %>%
  group_by(anio, producto) %>%
  summarise(
    precio_promedio = mean(precio, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  arrange(producto, anio) %>%
  group_by(producto) %>%
  mutate(
    variacion_interanual = (precio_promedio - lag(precio_promedio)) /
```

```

    lag(precio_promedio) * 100
  ) %>%
  ungroup() %>%
  mutate(across(where(is.numeric), ~ round(.x, 2)))
precio_anual_producto

```

```

## # A tibble: 50 x 4
##   anio producto      precio_promedio variacion_interanual
##   <dbl> <fct>          <dbl>                <dbl>
## 1 2017 Gas Oil Grado 2      19.3                  NA
## 2 2018 Gas Oil Grado 2      29.8                  54.2
## 3 2019 Gas Oil Grado 2      45.5                  52.8
## 4 2020 Gas Oil Grado 2      61.2                  34.5
## 5 2021 Gas Oil Grado 2      77.1                  25.9
## 6 2022 Gas Oil Grado 2     155.                  101.
## 7 2023 Gas Oil Grado 2     343.                  121.
## 8 2024 Gas Oil Grado 2    1106.                  223.
## 9 2025 Gas Oil Grado 2    1428.                   29.1
## 10 2026 Gas Oil Grado 2    2029.                  42.1
## # i 40 more rows

```

```

ggplot(precio_anual_producto, aes(x = anio, y = variacion_interanual)) +
  geom_line() +
  geom_point() +
  facet_wrap(~ producto) +
  labs(title = "Variación interanual del precio promedio", x = "Año", y = "Variación interanual (%)")

```

```

## Warning: Removed 5 rows containing missing values or values outside the scale range
## ('geom_line()').


```

```

## Warning: Removed 5 rows containing missing values or values outside the scale range
## ('geom_point()').

```

Variación interanual del precio promedio



Este análisis complementario permite estudiar no solo el nivel promedio de precios, sino también su variación a lo largo del tiempo. Como mejora futura, sería conveniente ajustar los precios por inflación para analizar precios reales.

15 Conclusión general

El trabajo permitió analizar una base de datos de precios históricos de combustibles en Paraná correspondiente al periodo 2017-2026. La base contiene información sobre productos, empresas, banderas comerciales, precios, fechas de vigencia y ubicación geográfica.

El análisis descriptivo permitió conocer la estructura general del dataset, la distribución de registros por producto, empresa, bandera comercial y año, así como el comportamiento general de la variable precio. No se detectaron problemas relevantes de datos faltantes.

Los intervalos de confianza permitieron estimar proporciones para variables cualitativas y medias para variables cuantitativas. En particular, se analizó la proporción de registros correspondientes a SHELL C.A.P.S.A. y la media del precio, tanto de manera general como por producto.

El análisis de asociación mostró la relación entre el tipo de producto y la bandera comercial, mientras que las correlaciones entre año y precio permitieron observar una tendencia creciente de los precios nominales a lo largo del tiempo.

La comparación de grupos se realizó mediante una prueba t de Welch para dos grupos independientes, comparando los precios de Nafta (súper) y Nafta (premium). Esta prueba fue seleccionada porque la variable **precio** es cuantitativa, los grupos comparados son independientes y no se asumió igualdad de varianzas. Los modelos lineales permitieron explicar parte de la variabilidad del precio a partir del año y del tipo de producto.

El análisis de outliers permitió detectar registros con valores atípicos en precio y en coordenadas geográficas. Estos casos deben interpretarse con cautela y podrían requerir revisión.

Finalmente, el análisis de componentes principales permitió reducir parcialmente la dimensión de las variables cuantitativas, mientras que el aporte personal permitió observar la evolución mensual y la variación interanual del precio promedio por producto.

En síntesis, el dataset muestra una tendencia creciente de los precios nominales de combustibles en Paraná, diferencias relevantes entre productos y asociaciones entre variables comerciales. Como líneas futuras de análisis se recomienda ajustar los precios por inflación, incorporar nuevas variables explicativas y profundizar el análisis predictivo.

16 Referencia del dataset

Fuente del dataset: Datos Abiertos de Energía de la República Argentina. Dataset de precios históricos de combustibles.