

Evaluación: Curso de Fundamentos de Ciencia de Datos


Introducción

La evaluación consiste en un desafío de clasificación de cultivos de verano utilizando información derivada de la colección de imágenes armonizadas Landsat Sentinel 2 (HLS). Las clases a predecir en el trabajo son: **'Soja', 'Maíz', 'Ganadería', 'Sorgo', 'Leñosas', y 'Girasol'**. El dataset tiene en total 294 variables generadas desde imágenes HLS y están agrupadas en tres momentos de la campaña de verano (Oct-Nov, Dic-Ene y Feb-Mar). Para esos 3 períodos se aplicaron medidas reductoras: percentiles (5%, 25%, 50%, 75% y 95%), media y desviación estándar. En la tabla 1 se describen las diferentes variables que fueron calculadas. Estas se dividen en Bandas, que son los canales observados por el satélite. Además, se incluyeron índices derivados desde las bandas [1].

Tabla 1: Detalle de variables

Tipo	Variables	Descripción	Reducciones
Bandas	blue, green, red, nir, swir1, swir2	Bandas espectrales HLS	Percentiles, media y desvío estándar
Índices	ndvi, ndwi, ndviL, ndsi, ndbi, evi, cig, vari	Índices espectrales derivados de las bandas	

El dataset presenta un serio desbalance hacia las clases de cultivos más frecuentes en Argentina Soja, Maíz, etc. Además, se incluyen clases que no son cultivos como Ganadería y Leñosas. La distribución de casos de entrenamiento se muestra en el gráfico 1.



Métrica de evaluación

La métrica de evaluación a maximizar será la **F1-Score Macro**¹. Esta medida calcula el F1-score de cada clase y saca un promedio simple, sin importar cuántos datos tenga cada una. Esta exigencia es para que se esfuercen en clasificar todas las clases y no solo las mayoritarias que tienen más peso.

Con sklearn la calculan como: `f1_score(y_test, y_pred, average="macro")`

Datos

- [cultivos-feature-space-train.csv](#): Contiene las variables predictoras que forman el espacio de características de entrenamiento.
- [cultivos-target-train.csv](#): Contiene las clases para train
- [cultivos-feature-space-test.csv](#): Contiene las variables predictoras que forman el espacio de características del test.

Baseline

Para aprobar el examen el grupo deberá superar el **F1-score Macro de 0.5**, si no se alcanza esa meta deberá realizar una nueva entrega.

¹ https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html

Entrega

Para la evaluación se requieren 2 entregas que consisten en:

1. Las predicciones realizadas para el conjunto de test ([cultivos-feature-space-test.csv](#)) en formato CSV.
2. Un informe de **máximo 4 páginas** en formato pdf identificado con el nombre del grupo. Es requisito que contenga una explicación somera del pipeline de clasificación, destacando las tareas de preprocesamiento realizadas y todos los detalles que el grupo considere necesario para describir el trabajo. Fuente: Arial, tamaño 11.

Fecha de entrega

Hay tiempo para enviar el trabajo hasta el **Domingo 14 de Junio 23:59:59 hora de Argentina**

Grupos

La conformación de los grupos debe ser de dos estudiantes y deben fijar los grupos en esta planilla [\[link\]](#).

Referencias

[1] An overview of the Spatial Analyst functions [link: [Band Indices](#)]