

Informe de clasificación de cultivos de verano

Curso de Fundamentos de Ciencia de Datos

1. Objetivo y datos utilizados

El objetivo del trabajo fue construir un pipeline de clasificación supervisada para predecir la clase de cultivo o cobertura en el conjunto de test. Se trabajó con 5703 registros de entrenamiento, 294 variables predictoras derivadas de imágenes HLS y 1426 registros de test. Las clases consideradas fueron: Ganadería, Girasol, Leñosas, Maíz, Soja y Sorgo.

El conjunto de entrenamiento presenta un desbalance importante: Soja, Maíz y Ganadería concentran la mayor parte de los registros, mientras que Girasol, Leñosas y Sorgo tienen mucha menor frecuencia. Por ese motivo se priorizó la métrica F1-score Macro, ya que evalúa el desempeño promedio por clase sin ponderar por cantidad de casos.




Figura 1. Distribución de clases en el conjunto de entrenamiento.

2. Pipeline de clasificación

El pipeline aplicado fue el siguiente:

Etapa	Descripción
Carga de datos	Lectura de los tres CSV: variables de entrenamiento, etiquetas y variables de test.
Control inicial	Verificación de dimensiones, tipos de datos y valores faltantes. Las 294 variables fueron numéricas y no tuvieron faltantes.
Codificación	Transformación de las etiquetas de clase a valores numéricos mediante LabelEncoder.
Balanceo	Aplicación de SMOTE solo sobre entrenamiento para generar ejemplos sintéticos de clases minoritarias.
Modelo	Entrenamiento de ExtraTreesClassifier con 300 árboles, max_features=sqrt y semilla fija.
Predicción final	Reentrenamiento con todos los datos disponibles y generación del CSV final de test.

3. Preprocesamiento realizado

No se eliminaron variables, porque todas se encontraban en formato numérico y provenían de reducciones temporales ya calculadas: medias, percentiles y desvíos estándar sobre bandas e índices espectrales. La tarea central de preprocesamiento fue tratar el desbalance de clases. Para ello se utilizó SMOTE dentro de un pipeline, evitando aplicarlo antes de separar entrenamiento y validación. Esto reduce el riesgo de filtración de información entre los datos usados para entrenar y los usados para validar.

El modelo elegido, ExtraTreesClassifier, es un ensamble de árboles de decisión aleatorizados. Se seleccionó porque funciona bien con muchas variables numéricas, no requiere escalado previo y permite capturar relaciones no lineales entre las bandas, índices y momentos de la

campañā.

4. Validación del modelo

Para estimar el desempeño se reservó un 20% del entrenamiento como validación estratificada. El resultado obtenido superó el baseline solicitado de 0,50 de F1-score Macro.

Métrica	Valor
F1-score Macro validación	0.660
Accuracy validación	0.814
F1-score ponderado	0.808

Clase	Precisión	Recall	F1-score	Soporte
Ganaderia	0.832	0.868	0.849	273
Girasol	0.571	0.333	0.421	12
Leñosas	0.889	0.696	0.780	23
Maiz	0.777	0.716	0.745	292
Soja	0.829	0.891	0.859	513
Sorgo	0.545	0.214	0.308	28




Figura 2. Matriz de confusión obtenida en la partición de validación.

5. Interpretación breve

El modelo mostró buen desempeño en las clases mayoritarias y en Leñosas. Las clases Girasol y Sorgo fueron las más difíciles por su baja cantidad de ejemplos originales. Aun así, el uso de SMOTE permitió que el modelo no se concentre únicamente en Soja, Maíz y Ganadería, mejorando el promedio macro respecto de un modelo sin tratamiento del desbalance.

Entre las variables más relevantes del modelo aparecen principalmente índices y bandas del período Oct-Nov, como `ndvi_p5_OctNov`, `vari_p5_OctNov`, `blue_p95_OctNov` y variables asociadas a SWIR y EVI. Esto sugiere que las diferencias tempranas de comportamiento espectral aportaron información útil para separar las clases.

6. Archivo de predicciones

Luego de validar el enfoque, se reentrenó el pipeline completo usando todos los datos de entrenamiento disponibles y se generó el archivo CSV de entrega con una columna llamada clase. Cada fila corresponde a la predicción de la fila equivalente del archivo cultivos-feature-space-test.csv.

Clase predicha	Cantidad
Soja	706
Ganaderia	358
Maiz	306
Sorgo	27
Leñosas	24
Girasol	5